

逻辑回归(Logistic Regression)

2019年11月7日 21:57

作者: zx青

逻辑回归算法

逻辑回归一般是用于解决分类问题，是将样本的特征和样本发生的概率联系起来，其中概率是一个数。

逻辑回归和线性回归同属于广义线性模型，逻辑回归就是用线性回归同属于广义线性模型，逻辑回归就是用线性回归的预测值去拟合真实标签的对数几率（一个事件的几率(odds)是指该事件发生的概率与不发生的概率之比，如果该事件发生的概率是 p ，那么该事件的几率是 $\frac{p}{1-p}$ ，对数几率就是 $\log \frac{p}{1-p}$ ）


逻辑回归和线性回归本质上都是得到一条直线，不同的是，线性回归的直线是尽可能去拟合输入变量 x 的分布，使得训练集中所有样本点到直线的距离最短；而逻辑回归的直线是尽可能去拟合决策边界，使得训练集样本中的样本点尽可能分离开，两者的目的是不同的。

1、Sigmoid函数

Sigmoid函数公式：

$$g(x) = \frac{1}{1 + e^{-(x)}}$$

当 x 趋近于无穷大时， $g(x)$ 趋近于1；当 x 趋近于无穷小时， $g(x)$ 趋近于0。



Sigmoid函数求导时有一个特性，这个特性将在下面的推导中用到，这个特性为：

$$\begin{aligned} g'(z) &= \frac{d}{dz} \frac{1}{1 + e^{-z}} \\ &= \frac{1}{(1 + e^{-z})^2} (e^{-z}) \\ &= \frac{1}{(1 + e^{-z})} \cdot \left(1 - \frac{1}{(1 + e^{-z})}\right) \\ &= g(z)(1 - g(z)). \end{aligned}$$

2、逻辑回归

逻辑回归本质上是线性回归，只是在特征到结果的映射中加入了一层函数映射，即先把特征线性求和，然后使用函数 $g(z)$ 将最为假设函数来预测。 $g(z)$ 可以将连续值映射到0到1之间。


通过将线性模型和Sigmoid函数结合，就可以得到逻辑回归的公式： $h_{\theta}(x) = g(\theta^T x) = \frac{1}{1+e^{-(\theta^T x)}}$ ， $h_{\theta}(x)$ 的值为 $[0, 1]$

对式子变形可得： $\log \frac{y}{1-y} = \theta^T x$ （对数几率公式）

二项Logistic回归：

多项Logistic回归：

3、逻辑回归算法的损失函数



$cost \begin{cases} \text{如果 } y = 1, h_{\theta}(x) \text{ 越小, } cost \text{ 越大} \\ \text{如果 } y = 0, h_{\theta}(x) \text{ 越大, } cost \text{ 越大} \end{cases}$

$$cost \begin{cases} -\log(h_{\theta}(x)), & \text{if } y = 1 \\ -\log(1 - h_{\theta}(x)), & \text{if } y = 0 \end{cases} \Rightarrow cost = -y \log(h_{\theta}(x)) - (1 - y) \log(1 - h_{\theta}(x))$$

对于 m 个样本，总的损失函数为

$$J(\theta) = -\frac{1}{m} \sum_{i=1}^m y_i \log(h_{\theta}(x_i)) - (1 - y_i) \log(1 - h_{\theta}(x_i))$$

m 是样本数， y 是标签，取值为0或1， i 表示第 i 个样本， $h_{\theta}(x_i)$ 表示预测的输出。

4、逻辑回归算法损失函数求解

$$J(\theta) = -\frac{1}{m} \sum_{i=1}^m y_i \log(h_{\theta}(x_i)) - (1 - y_i) \log(1 - h_{\theta}(x_i)) \quad \log(h_{\theta}(x_i))' = 1 - h_{\theta}(x_i)$$

$$\nabla J(\theta) = \begin{bmatrix} \frac{\partial J(\theta)}{\partial \theta_0} \\ \frac{\partial J(\theta)}{\partial \theta_1} \\ \vdots \\ \frac{\partial J(\theta)}{\partial \theta_n} \end{bmatrix}$$

$$J(\theta) = -\frac{1}{m} \sum_{i=1}^m y_i \log(g(\theta^T x_i)) - (1 - y_i) \log(1 - g(\theta^T x_i))$$

$$(\log(g(\theta^T x_i)))' = 1 - g(\theta^T x_i)$$

$$\frac{d(y_i \log(g(\theta^T x_i)))}{d\theta_j} = y_i(1 - g(\theta^T x_i))x_j$$

$$\frac{\Delta J(\theta)}{\Delta \theta_j} = \frac{1}{m} \sum_{i=1}^m (g(\theta^T x_i) - y_i) x_j = \frac{1}{m} \sum_{i=1}^m (\hat{y}_i - y_i) x_j = \frac{1}{m} X^T (g(\theta^T x_i) - y)$$

5、逻辑回归算法的python代码实现

https://github.com/zx-qing/Machine_Learning/blob/master/Logistic_Regression/logicRegression.ipynb